

Análise Léxica



Universidade Federal do Ceará - Campus de Quixadá

Lucas Ismaily
ismailybf@ufc.br

Semestre 2025.1


Compiladores

Baseado nos slides do Prof. Sandro Rigo (IC-Unicamp)


Seção 1

Introdução

Introdução




Introdução




- O compilador traduz o programa de uma linguagem (fonte) para outra (de máquina).

Introdução



- O compilador traduz o programa de uma linguagem (fonte) para outra (de máquina).
- Esse processo demanda sua quebra em várias partes, o entendimento de sua estrutura e significado.

Introdução



- O compilador traduz o programa de uma linguagem (fonte) para outra (de máquina).
- Esse processo demanda sua quebra em várias partes, o entendimento de sua estrutura e significado.
- O responsável por esse tipo de análise é o front-end.

Front-end

- Análise Léxic:

Front-end

- Análise Léxica:
 - Quebra a entrada em palavras conhecidas como símbolos léxicos (tokens).

Front-end

- Análise Léxica:
 - Quebra a entrada em palavras conhecidas como símbolos léxicos (tokens).
- Análise Sintática:

Front-end

- Análise Léxica:
 - Quebra a entrada em palavras conhecidas como símbolos léxicos (tokens).
- Análise Sintática:
 - Analisa a estrutura de frases do programa.

Front-end

- Análise Léxica:
 - Quebra a entrada em palavras conhecidas como símbolos léxicos (tokens).
- Análise Sintática:
 - Analisa a estrutura de frases do programa.
- Análise Semântica:

Front-end

- Análise Léxica:
 - Quebra a entrada em palavras conhecidas como símbolos léxicos (tokens).
- Análise Sintática:
 - Analisa a estrutura de frases do programa.
- Análise Semântica:
 - Calcula o significado do programa.

Cadeias e Linguagens

- Alfabeto

Cadeias e Linguagens

- Alfabeto
 - Conjunto finito não vazio de símbolos.

Cadeias e Linguagens

- Alfabeto
 - Conjunto finito não vazio de símbolos.
 - Exemplos:

Cadeias e Linguagens

- Alfabeto
 - Conjunto finito não vazio de símbolos.
 - Exemplos:
 - $\Sigma_1 = \{0, 1\}$

Cadeias e Linguagens

- Alfabeto
 - Conjunto finito não vazio de símbolos.
 - Exemplos:
 - $\Sigma_1 = \{0, 1\}$
 - $\Sigma_2 = \{a, b, c, d, \dots, z\}$

Cadeias e Linguagens

- Alfabeto
 - Conjunto finito não vazio de símbolos.
 - Exemplos:
 - $\Sigma_1 = \{0, 1\}$
 - $\Sigma_2 = \{a, b, c, d, \dots, z\}$
- Cadeia

Cadeias e Linguagens

- Alfabeto
 - Conjunto finito não vazio de símbolos.
 - Exemplos:
 - $\Sigma_1 = \{0, 1\}$
 - $\Sigma_2 = \{a, b, c, d, \dots, z\}$
- Cadeia
 - Sequência finita de símbolos de um alfabeto

Cadeias e Linguagens

- Alfabeto
 - Conjunto finito não vazio de símbolos.
 - Exemplos:
 - $\Sigma_1 = \{0, 1\}$
 - $\Sigma_2 = \{a, b, c, d, \dots, z\}$
- Cadeia
 - Sequência finita de símbolos de um alfabeto
 - 010010 é cadeia sobre Σ_1 de tamanho 6.

Cadeias e Linguagens

- Alfabeto
 - Conjunto finito não vazio de símbolos.
 - Exemplos:
 - $\Sigma_1 = \{0, 1\}$
 - $\Sigma_2 = \{a, b, c, d, \dots, z\}$
- Cadeia
 - Sequência finita de símbolos de um alfabeto
 - 010010 é cadeia sobre Σ_1 de tamanho 6.
 - O símbolo ε denota cadeia vazia de comprimento zero.

Cadeias e Linguagens

- Dado uma cadeia w sobre Σ :

Cadeias e Linguagens

- Dado uma cadeia w sobre Σ :
 - $w^0 = \varepsilon$

Cadeias e Linguagens

- Dado uma cadeia w sobre Σ :
 - $w^0 = \varepsilon$
 - $w^k = w^{k-1}w$ para $k > 0$ (concatenação k vezes)

Cadeias e Linguagens

- Dado uma cadeia w sobre Σ :
 - $w^0 = \varepsilon$
 - $w^k = w^{k-1}w$ para $k > 0$ (concatenação k vezes)
- Dado um alfabeto Σ :

Cadeias e Linguagens

- Dado uma cadeia w sobre Σ :
 - $w^0 = \varepsilon$
 - $w^k = w^{k-1}w$ para $k > 0$ (concatenação k vezes)
- Dado um alfabeto Σ :
 - Σ^* é o conjunto de todas as cadeias finitas sobre Σ .

Cadeias e Linguagens

- Dado uma cadeia w sobre Σ :
 - $w^0 = \varepsilon$
 - $w^k = w^{k-1}w$ para $k > 0$ (concatenação k vezes)
- Dado um alfabeto Σ :
 - Σ^* é o conjunto de todas as cadeias finitas sobre Σ .
 - Σ^+ é o conjunto de todas as cadeias finitas sobre Σ menos a cadeia vazia.

Cadeias e Linguagens

- Dado uma cadeia w sobre Σ :
 - $w^0 = \varepsilon$
 - $w^k = w^{k-1}w$ para $k > 0$ (concatenação k vezes)
- Dado um alfabeto Σ :
 - Σ^* é o conjunto de todas as cadeias finitas sobre Σ .
 - Σ^+ é o conjunto de todas as cadeias finitas sobre Σ menos a cadeia vazia.
- Linguagem

Cadeias e Linguagens

- Dado uma cadeia w sobre Σ :
 - $w^0 = \varepsilon$
 - $w^k = w^{k-1}w$ para $k > 0$ (concatenação k vezes)
- Dado um alfabeto Σ :
 - Σ^* é o conjunto de todas as cadeias finitas sobre Σ .
 - Σ^+ é o conjunto de todas as cadeias finitas sobre Σ menos a cadeia vazia.
- Linguagem
 - Conjunto de todas cadeias de um alfabeto.

Cadeias e Linguagens

- Linguagem sobre Σ

Cadeias e Linguagens

- Linguagem sobre Σ
 - Conjunto de cadeias em Σ .

Cadeias e Linguagens

- Linguagem sobre Σ
 - Conjunto de cadeias em Σ .
 - Subconjunto de Σ^* .

Cadeias e Linguagens

- Linguagem sobre Σ
 - Conjunto de cadeias em Σ .
 - Subconjunto de Σ^* .
- Dadas L_1 e L_2 linguagens sobre Σ :

Cadeias e Linguagens

- Linguagem sobre Σ
 - Conjunto de cadeias em Σ .
 - Subconjunto de Σ^* .
- Dadas L_1 e L_2 linguagens sobre Σ :
 - $L_1 \cup L_2 = \{x | x \in L_1 \text{ ou } x \in L_2\}$

Cadeias e Linguagens

- Linguagem sobre Σ
 - Conjunto de cadeias em Σ .
 - Subconjunto de Σ^* .
- Dadas L_1 e L_2 linguagens sobre Σ :
 - $L_1 \cup L_2 = \{x | x \in L_1 \text{ ou } x \in L_2\}$
 - $L_1.L_2 = \{xy | x \in L_1 \text{ e } y \in L_2\}$

Cadeias e Linguagens

- Linguagem sobre Σ
 - Conjunto de cadeias em Σ .
 - Subconjunto de Σ^* .
- Dadas L_1 e L_2 linguagens sobre Σ :
 - $L_1 \cup L_2 = \{x \mid x \in L_1 \text{ ou } x \in L_2\}$
 - $L_1.L_2 = \{xy \mid x \in L_1 \text{ e } y \in L_2\}$
 - $L_1^* = \{x_1, x_2, \dots, x_k \mid k \geq 0 \text{ e cada } x_i \in L_1\}$

Cadeias e Linguagens

- Linguagem livre de contexto:

Cadeias e Linguagens

- Linguagem livre de contexto:
 - Linguagens descritas por uma gramática livre de contexto.

Cadeias e Linguagens

- Linguagem livre de contexto:
 - Linguagens descritas por uma gramática livre de contexto.
 - Úteis para especificar linguagens de programação.

Cadeias e Linguagens

- Linguagem livre de contexto:
 - Linguagens descritas por uma gramática livre de contexto.
 - Úteis para especificar linguagens de programação.
 - Vamos estudar com mais detalhes a seguir.

Cadeias e Linguagens

- Linguagem livre de contexto:
 - Linguagens descritas por uma gramática livre de contexto.
 - Úteis para especificar linguagens de programação.
 - Vamos estudar com mais detalhes a seguir.
- Linguagens regulares:

Cadeias e Linguagens

- Linguagem livre de contexto:
 - Linguagens descritas por uma gramática livre de contexto.
 - Úteis para especificar linguagens de programação.
 - Vamos estudar com mais detalhes a seguir.
- Linguagens regulares:
 - Caso particular de linguagens livre de contexto.

Cadeias e Linguagens

- Linguagem livre de contexto:
 - Linguagens descritas por uma gramática livre de contexto.
 - Úteis para especificar linguagens de programação.
 - Vamos estudar com mais detalhes a seguir.
- Linguagens regulares:
 - Caso particular de linguagens livre de contexto.
 - Linguagens que podem ser descritas através de expressões regulares ou reconhecidas por autômatos finitos.

Analizador Léxico

- Recebe uma sequência de caracteres e produz uma sequência de palavras chaves, pontuação e nomes.

Analizador Léxico

- Recebe uma sequência de caracteres e produz uma sequência de palavras chaves, pontuação e nomes.
- Descarta comentários e espaços em branco.

Símbolos Léxicos

Tipo	Exemplos
ID	foo n14 last var
NUM	15 13 2 1 2 5 121
REAL	1.2 .533 1e66.4 24.5e-10
IF	if
COMMA	,
NOTEQ	!=
EQ	==
LPAREN	(

Não Símbolos

Tipo	Exemplos
<i>Comentário</i>	<code>/*try again*/</code>
<i>Diretivas de pré-processamento</i>	<code>#include <stdio.h></code>
<i>Diretivas de pré-processamento</i>	<code>#define NUMS 5,6</code>
<i>macro</i>	<code>NUMS</code>
<i>Linhas em branco, tabs e novas linhas</i>	

Exemplo

```
float match0(char *s) /* find a zero*/  
    if (!strncmp(s, ``0.0'',3))  
        return .0;  
}
```

Exemplo

```
float match0(char *s) /* find a zero*/  
    if (!strncmp(s, ``0.0'',3))  
        return .0;  
}
```

Retorno do analisador léxico:

```
FLOAT ID ( match0 ) LPAREN CHAR STAR ID(s) RPAREN LBRACE IF  
LPAREN BANG ID(strncmp) LPAREN ID (s) COMMA STRING ( 0.0 )  
COMMA NUM (3) RPAREN RPAREN RETURN REAL ( 0.0 ) SEMI  
RBRACE EOF
```

Exemplo

```
int paridade(int n) /* é par? */  
{  
    if (n%2==0)  
        return 1;  
    else return 0;  
}
```

Retorno do analisador léxico:

???

Analizador Léxico

- Alguns símbolos têm um valor semântico associados a eles:

Analizador Léxico

- Alguns símbolos têm um valor semântico associados a eles:
 - IDs e NUMs.

Analizador Léxico

- Alguns símbolos têm um valor semântico associados a eles:
 - IDs e NUMs.
- Como são descritas as regras lexicográficas?

Analizador Léxico

- Alguns símbolos têm um valor semântico associados a eles:
 - IDs e NUMs.
- Como são descritas as regras lexicográficas?

Um identificador é uma sequência de letras e dígitos; o primeiro caractere deve ser uma letra. O underscore “_” conta como uma letra. Letras maiúsculas e minúsculas são diferentes. Se o fluxo de entrada resultar em um símbolo até um dado caractere, o próximo caractere é lido visando encontrar a maior string de caracteres possível que constitua um símbolo. Espaços, tabs, novas linhas e comentários são ignorados exceto quando eles servem de separadores de símbolos. Um espaço em branco é usado para separar identificadores adjacentes, palavras chaves e constantes.

Analizador Léxico

- Alguns símbolos têm um valor semântico associados a eles:
 - IDs e NUMs.
- Como são descritas as regras lexicográficas?

Um identificador é uma sequência de letras e dígitos; o primeiro caractere deve ser uma letra. O underscore “_” conta como uma letra. Letras maiúsculas e minúsculas são diferentes. Se o fluxo de entrada resultar em um símbolo até um dado caractere, o próximo caractere é lido visando encontrar a maior string de caracteres possível que constitua um símbolo. Espaços, tabs, novas linhas e comentários são ignorados exceto quando eles servem de separadores de símbolos. Um espaço em branco é usado para separar identificadores adjacentes, palavras chaves e constantes.

- Como os tokens são especificados?

Expressões Regulares

- Uma linguagem é um conjunto de strings.

Expressões Regulares

- Uma linguagem é um conjunto de strings.
- Uma string é uma sequência de símbolos.

Expressões Regulares

- Uma linguagem é um conjunto de strings.
- Uma string é uma sequência de símbolos.
- Estes símbolos estão definidos em um alfabeto finito

Expressões Regulares

- Uma linguagem é um conjunto de strings.
- Uma string é uma sequência de símbolos.
- Estes símbolos estão definidos em um alfabeto finito
 - Ex.: Linguagem C ou Pascal, linguagem dos primos, etc.

Expressões Regulares

- Uma linguagem é um conjunto de strings.
- Uma string é uma sequência de símbolos.
- Estes símbolos estão definidos em um alfabeto finito
 - Ex.: Linguagem C ou Pascal, linguagem dos primos, etc.
- Queremos poder dizer se uma string está ou não em uma linguagem.

Expressões Regulares

- **Símbolos:** Para cada símbolo a no alfabeto da linguagem, a expressão regular a representa a linguagem contendo somente a string a ;

Expressões Regulares

- **Símbolos:** Para cada símbolo a no alfabeto da linguagem, a expressão regular a representa a linguagem contendo somente a string a ;
- **Alternação:** Dadas duas expressões regulares M e N , o operador de alternância ($|$) gera uma nova expressão $M|N$. Uma string está na linguagem de $M|N$ se ela está na linguagem de M ou na linguagem de N .

Expressões Regulares

- **Símbolos:** Para cada símbolo a no alfabeto da linguagem, a expressão regular a representa a linguagem contendo somente a string a ;
- **Alternância:** Dadas duas expressões regulares M e N , o operador de alternância ($|$) gera uma nova expressão $M|N$. Uma string está na linguagem de $M|N$ se ela está na linguagem de M ou na linguagem de N .
 - Ex.: A linguagem de $a|b$ contém as duas strings a e b .

Expressões Regulares

- **Concatenação:** Dadas duas expressões regulares M e N , o operador de concatenação $(\cdot)$ gera uma nova expressão $M \cdot N$. Uma string está na linguagem de $M \cdot N$ se ela é a concatenação de quaisquer duas strings α e β , tal que α está na linguagem de M e β está na linguagem de N .

Expressões Regulares

- **Concatenação:** Dadas duas expressões regulares M e N , o operador de concatenação $(\cdot)$ gera uma nova expressão $M \cdot N$. Uma string está na linguagem de $M \cdot N$ se ela é a concatenação de quaisquer duas strings α e β , tal que α está na linguagem de M e β está na linguagem de N .
 - Ex.: $(a|b) \cdot a$ contém as strings aa e ba .

Expressões Regulares

- **Concatenação:** Dadas duas expressões regulares M e N , o operador de concatenação $(\cdot)$ gera uma nova expressão $M \cdot N$. Uma string está na linguagem de $M \cdot N$ se ela é a concatenação de quaisquer duas strings α e β , tal que α está na linguagem de M e β está na linguagem de N .
 - Ex.: $(a|b) \cdot a$ contém as strings aa e ba .
- **Epsilon:** A expressão regular ε representa a linguagem cuja única string é a vazia.

Expressões Regulares

- **Concatenação:** Dadas duas expressões regulares M e N , o operador de concatenação $(\cdot)$ gera uma nova expressão $M \cdot N$. Uma string está na linguagem de $M \cdot N$ se ela é a concatenação de quaisquer duas strings α e β , tal que α está na linguagem de M e β está na linguagem de N .
 - Ex.: $(a|b) \cdot a$ contém as strings aa e ba .
- **Epsilon:** A expressão regular ε representa a linguagem cuja única string é a vazia.
 - Ex.: $(a \cdot b)|\varepsilon$ representa a linguagem $\{\epsilon, "ab"\}$.

Expressões Regulares

- **Repetição:** Dada uma expressão regular M , seu Kleene closure é M^* . Uma string está em M^* se ela é a concatenação de zero ou mais strings, todas em M .

Expressões Regulares

- **Repetição:** Dada uma expressão regular M , seu Kleene closure é M^* . Uma string está em M^* se ela é a concatenação de zero ou mais strings, todas em M .
 - Ex.: $((a|b) \cdot a)^*$ representa $\{ "", "aa", "ba", "aaaa", "baaa", "aaba", "baba", "aaaaa", \dots \}$.

Expressões Regulares

- $(0|1)^* \cdot 0$

Expressões Regulares

- $(0|1)^* \cdot 0$
 - Números binários múltiplos de 2.

Expressões Regulares

- $(0|1)^* \cdot 0$
 - Números binários múltiplos de 2.
- $b^*(abb^*)^*(a|\varepsilon)$

Expressões Regulares

- $(0|1)^* \cdot 0$
 - Números binários múltiplos de 2.
- $b^*(abb^*)^*(a|\varepsilon)$
 - Strings de a 's e b 's sem a 's consecutivos.

Expressões Regulares

- $(0|1)^* \cdot 0$
 - Números binários múltiplos de 2.
- $b^*(abb^*)^*(a|\varepsilon)$
 - Strings de a 's e b 's sem a 's consecutivos.
- $(a|b)^*aa(a|b)^*$

Expressões Regulares

- $(0|1)^* \cdot 0$
 - Números binários múltiplos de 2.
- $b^*(abb^*)^*(a|\varepsilon)$
 - Strings de a 's e b 's sem a 's consecutivos.
- $(a|b)^*aa(a|b)^*$
 - Strings de a 's e b 's com a 's consecutivos.

Notação

- a - Um caractere ordinário por se só.

Notação

- a - Um caractere ordinário por se só.
- ε - A string vazia.

Notação

- a - Um caractere ordinário por se só.
- ε - A string vazia.
- λ - Outra forma de escrever a string vazia.

Notação

- a - Um caractere ordinário por se só.
- ε - A string vazia.
- λ - Outra forma de escrever a string vazia.
- $M|N$ - Alternação.

Notação

- a - Um caractere ordinário por se só.
- ε - A string vazia.
- λ - Outra forma de escrever a string vazia.
- $M|N$ - Alternação.
- $M \cdot N$ - Concatenação.

Notação

- a - Um caractere ordinário por se só.
- ε - A string vazia.
- λ - Outra forma de escrever a string vazia.
- $M|N$ - Alternação.
- $M \cdot N$ - Concatenação.
- MN - Outra forma de concatenação.

Notação

- a - Um caractere ordinário por se só.
- ε - A string vazia.
- λ - Outra forma de escrever a string vazia.
- $M|N$ - Alternação.
- $M \cdot N$ - Concatenação.
- MN - Outra forma de concatenação.
- M^* - Repetição (zero ou mais vezes).

Notação

- a - Um caractere ordinário por se só.
- ε - A string vazia.
- λ - Outra forma de escrever a string vazia.
- $M|N$ - Alternação.
- $M \cdot N$ - Concatenação.
- MN - Outra forma de concatenação.
- M^* - Repetição (zero ou mais vezes).
- M^+ - Repetição (uma ou mais vezes).

Notação

- a - Um caractere ordinário por se só.
- ε - A string vazia.
- λ - Outra forma de escrever a string vazia.
- $M|N$ - Alternação.
- $M \cdot N$ - Concatenação.
- MN - Outra forma de concatenação.
- M^* - Repetição (zero ou mais vezes).
- M^+ - Repetição (uma ou mais vezes).
- $M?$ - Opcional, zero ou uma ocorrência de M .

Notação

- a - Um caractere ordinário por se só.
- ε - A string vazia.
- λ - Outra forma de escrever a string vazia.
- $M|N$ - Alternação.
- $M \cdot N$ - Concatenação.
- MN - Outra forma de concatenação.
- M^* - Repetição (zero ou mais vezes).
- M^+ - Repetição (uma ou mais vezes).
- $M?$ - Opcional, zero ou uma ocorrência de M .
- $[a - zA - Z]$ - Conjunto de caracteres alterados.

Notação

- a - Um caractere ordinário por se só.
- ε - A string vazia.
- λ - Outra forma de escrever a string vazia.
- $M|N$ - Alternação.
- $M \cdot N$ - Concatenação.
- MN - Outra forma de concatenação.
- M^* - Repetição (zero ou mais vezes).
- M^+ - Repetição (uma ou mais vezes).
- $M?$ - Opcional, zero ou uma ocorrência de M .
- $[a - zA - Z]$ - Conjunto de caracteres alterados.
- $.$ - Representa qualquer caractere, exceto nova linha.

Notação

- a - Um caractere ordinário por se só.
- ε - A string vazia.
- λ - Outra forma de escrever a string vazia.
- $M|N$ - Alternação.
- $M \cdot N$ - Concatenação.
- MN - Outra forma de concatenação.
- M^* - Repetição (zero ou mais vezes).
- M^+ - Repetição (uma ou mais vezes).
- $M?$ - Opcional, zero ou uma ocorrência de M .
- $[a - zA - Z]$ - Conjunto de caracteres alterados.
- $.$ - Representa qualquer caractere, exceto nova linha.
- $"a.+^*"$ - Uma string de caracteres.

Expressões Regulares

- Como seriam as expressões regulares para os seguintes tokens?

Expressões Regulares

- Como seriam as expressões regulares para os seguintes tokens?
 - IF

Expressões Regulares

- Como seriam as expressões regulares para os seguintes tokens?
 - IF
 - if

Expressões Regulares

- Como seriam as expressões regulares para os seguintes tokens?
 - IF
 - if
 - ID

Expressões Regulares

- Como seriam as expressões regulares para os seguintes tokens?
 - IF
 - if
 - ID
 - $[a-z][a-zA-Z0-9]^*$

Expressões Regulares

- Como seriam as expressões regulares para os seguintes tokens?
 - IF
 - if
 - ID
 - $[a-z][a-z0-9]^*$
 - NUM

Expressões Regulares

- Como seriam as expressões regulares para os seguintes tokens?
 - IF
 - if
 - ID
 - $[a - z][a - z0 - 9]^*$
 - NUM
 - $[0 - 9]^+$

Expressões Regulares

- Quais símbolos representam as seguintes expressões regulares?
 - $[0-9]^+ " [0-9]^*) ([0-9]^* " [0-9]^+)$
 - ???
 - $(" - " [a-z]^* " \backslash n) ((" " | " \backslash n " | " \backslash t ")^+$
 - ???
 - .
 - ???

Expressões Regulares

- Quais símbolos representam as seguintes expressões regulares?
 - $[0-9]^+ " \cdot "[0-9]^*) ([0-9]^+ " \cdot "[0-9]^+)$
 - ??? REAL
 - $("- "[a-z]^* "\n") (" " | "\n" | "\t")^+$
 - ??? nenhum token, somente comentário, brancos, nova linha e tab
 - .
 - ??? ERROR

Analizador Léxico

- Ambiguidade:

Analizador Léxico

- Ambiguidade:
 - if8 é um ID ou dois tokens IF e NUM(8)?

Analizador Léxico

- Ambiguidade:
 - if8 é um ID ou dois tokens IF e NUM(8)?
 - if 89 começa com um ID ou uma palavra-reservada?

Analizador Léxico

- Ambiguidade:
 - if8 é um ID ou dois tokens IF e NUM(8)?
 - if 89 começa com um ID ou uma palavra-reservada?
- Duas regras:

Analizador Léxico

- Ambiguidade:
 - if8 é um ID ou dois tokens IF e NUM(8)?
 - if 89 começa com um ID ou uma palavra-reservada?
- Duas regras:
 - Maior casamento: o próximo símbolo sempre é a substring mais longa possível de ser casada.

Analizador Léxico

- Ambiguidade:
 - if8 é um ID ou dois tokens IF e NUM(8)?
 - if 89 começa com um ID ou uma palavra-reservada?
- Duas regras:
 - Maior casamento: o próximo símbolo sempre é a substring mais longa possível de ser casada.
 - Prioridade: Para uma dada substring mais longa, a primeira regra a ser casada produzirá o token.

Analizador Léxico

- A especificação deve ser completa, sempre reconhecendo uma substring da entrada

Analizador Léxico

- A especificação deve ser completa, sempre reconhecendo uma substring da entrada
 - Mas quando estiver errada? Use uma regra com o “.”

Analizador Léxico

- A especificação deve ser completa, sempre reconhecendo uma substring da entrada
 - Mas quando estiver errada? Use uma regra com o “.”
 - Em que lugar da sua especificação deve estar esta regra?

Analizador Léxico

- A especificação deve ser completa, sempre reconhecendo uma substring da entrada
 - Mas quando estiver errada? Use uma regra com o “.”
 - Em que lugar da sua especificação deve estar esta regra?
- Esta regra deve ser a última! (Por que?)

Seção 2

Autômatos Finitos

Autômatos Finitos

- Expressões regulares são convenientes para especificar os símbolos.

Autômatos Finitos

- Expressões regulares são convenientes para especificar os símbolos.
- Precisamos de um formalismo que possa ser convertido em um programa de computador.

Autômatos Finitos

- Expressões regulares são convenientes para especificar os símbolos.
- Precisamos de um formalismo que possa ser convertido em um programa de computador.
- Este formalismo são os autômatos finitos.

Autômatos Finitos

- Um autômato finito possui:

Autômatos Finitos

- Um autômato finito possui:
 - Um conjunto finito de estados.

Autômatos Finitos

- Um autômato finito possui:
 - Um conjunto finito de estados.
 - Arestas levando de um estado a outro, anotada com um símbolo.

Autômatos Finitos

- Um autômato finito possui:
 - Um conjunto finito de estados.
 - Arestas levando de um estado a outro, anotada com um símbolo.
 - Um estado inicial.


Autômatos Finitos

- Um autômato finito possui:
 - Um conjunto finito de estados.
 - Arestas levando de um estado a outro, anotada com um símbolo.
 - Um estado inicial.
 - Um ou mais estados finais.


Autômatos Finitos

- Um autômato finito possui:
 - Um conjunto finito de estados.
 - Arestas levando de um estado a outro, anotada com um símbolo.
 - Um estado inicial.
 - Um ou mais estados finais.
 - Normalmente os estados são numerados ou nomeados para facilitar a manipulação e discussão.


Autômatos Finitos




IF




ID




NUM



REAL



white space



error

Autômato Finito Determinístico

- DFAs não podem apresentar duas arestas que deixam o mesmo estado, anotadas com o mesmo símbolo.

Autômato Finito Determinístico

- DFAs não podem apresentar duas arestas que deixam o mesmo estado, anotadas com o mesmo símbolo.
- Saindo do estado inicial, o autômato segue exatamente uma aresta para cada caractere da entrada.

Autômato Finito Determinístico

- DFAs não podem apresentar duas arestas que deixam o mesmo estado, anotadas com o mesmo símbolo.
- Saindo do estado inicial, o autômato segue exatamente uma aresta para cada caractere da entrada.
- O DFA aceita a string se, após percorrer todos os caracteres, ele estiver em um estado final

Autômato Finito Determinístico

- Se em algum momento não houver uma aresta a ser percorrida para um determinado caractere ou ele terminar em um estado não-final, a string é rejeitada.

Autômato Finito Determinístico

- Se em algum momento não houver uma aresta a ser percorrida para um determinado caractere ou ele terminar em um estado não-final, a string é rejeitada.
- A linguagem reconhecida pelo autômato é o conjunto de todas as strings que ele aceita.

Autômato Finito Determinístico

- Consigo combinar os autômatos definidos para cada símbolo de maneira a ter um único autômato que possa ser usado como analisador léxico?


Autômato Finito Determinístico

- Consigo combinar os autômatos definidos para cada símbolo de maneira a ter um único autômato que possa ser usado como analisador léxico?
 - Sim.

Autômato Finito Determinístico

- Consigo combinar os autômatos definidos para cada símbolo de maneira a ter um único autômato que possa ser usado como analisador léxico?
 - Sim.
 - Veremos um exemplo ad-hoc e mais adiante mecanismos formais para esta tarefa.

Autômatos Finitos



Autômato Combinado

- Estados finais nomeados com o respectivo símbolo.

Autômato Combinado

- Estados finais nomeados com o respectivo símbolo.
- Alguns estados apresentam características de mais de um autômato anterior.

Autômato Combinado

- Estados finais nomeados com o respectivo símbolo.
- Alguns estados apresentam características de mais de um autômato anterior.
 - Ex.: 2.

Autômato Combinado

- Estados finais nomeados com o respectivo símbolo.
- Alguns estados apresentam características de mais de um autômato anterior.
 - Ex.: 2.
- Como ocorre a quebra de ambiguidade entre ID e IF?

Autômato Combinado

```
int edges[][] = { /* ... 0 1 2 ... - ... e f g h i j ... */ —ENTRADA—  
/* state 0 */      {0,0, ... 0,0,0 ... 0 ... 0,0,0,0,0,0 ... }, -N ARESTAS-  
/* state 1 */      {0,0, ... 7,7,7 ... 9 ... 4,4,4,4,2,4 ... },  
/* state 2 */      {0,0, ... 4,4,4 ... 0 ... 4,3,4,4,4,4 ... },  
/* state 3 */      {0,0, ... 4,4,4 ... 0 ... 4,4,4,4,4,4 ... },  
/* state 4 */      {0,0, ... 4,4,4 ... 0 ... 4,4,4,4,4,4 ... },  
/* state 5 */      {0,0, ... 6,6,6 ... 0 ... 0,0,0,0,0,0 ... },  
/* state 6 */      {0,0, ... 6,6,6 ... 0 ... 0,0,0,0,0,0 ... },  
/* state 7 */      {0,0, ... 7,7,7 ... 0 ... 0,0,0,0,0,0 ... },  
/* state 8 */      {0,0, ... 8,8,8 ... 0 ... 0,0,0,0,0,0 ... },  
etc }
```

Maior Substring

- A tabela anterior é usada para aceitar ou recusar uma string.

Maior Substring

- A tabela anterior é usada para aceitar ou recusar uma string.
- Porém, precisamos garantir que a maior string seja reconhecida.

Maior Substring

- A tabela anterior é usada para aceitar ou recusar uma string.
- Porém, precisamos garantir que a maior string seja reconhecida.
- Necessitamos de duas informações.

Maior Substring

- A tabela anterior é usada para aceitar ou recusar uma string.
- Porém, precisamos garantir que a maior string seja reconhecida.
- Necessitamos de duas informações.
 - Último estado final.

Maior Substring

- A tabela anterior é usada para aceitar ou recusar uma string.
- Porém, precisamos garantir que a maior string seja reconhecida.
- Necessitamos de duas informações.
 - Último estado final.
 - Posição da entrada no último estado final.

Maior Substring

Last Final	Current State	Current Input	Accept Action
0	1	<u>i</u> f --not-a-com	
2	2	if <u>f</u> --not-a-com	
3	3	if <u> </u> --not-a-com	
3	0	if <u> </u> --not-a-com	<i>return IF</i>
0	1	if <u> </u> --not-a-com	
12	12	if <u> </u> --not-a-com	
12	0	if <u> </u> --not-a-com	<i>found white space; resume</i>
0	1	if <u> </u> --not-a-com	
9	9	if <u> </u> --not-a-com	
9	10	if <u> </u> --not-a-com	
9	10	if <u> </u> --not-a-com	
9	10	if <u> </u> --not-a-com	
9	10	if <u> </u> --not-a-com	
9	0	if <u> </u> --not-a-com	<i>error, illegal token '-'; resume</i>
0	1	if <u> </u> --not-a-com	
9	9	if <u> </u> --not-a-com	
9	0	if <u> </u> --not-a-com	<i>error, illegal token '-'; resume</i>

Autômato Finito Não-Determinístico

- Pode ter mais de uma aresta saindo do mesmo estado com o mesmo símbolo.


Autômato Finito Não-Determinístico

- Pode ter mais de uma aresta saindo do mesmo estado com o mesmo símbolo.
- Pode ter arestas anotadas com o símbolo ε .


Autômato Finito Não-Determinístico

- Pode ter mais de uma aresta saindo do mesmo estado com o mesmo símbolo.
- Pode ter arestas anotadas com o símbolo ε .
 - Essa aresta pode ser percorrida sem consumir nenhum caractere de entrada.

Autômato Finito Não-Determinístico




Autômato Finito Não-Determinístico




- Que linguagem este autômato reconhece?

Autômato Finito Não-Determinístico




- Que linguagem este autômato reconhece?
 - **Obs.:** Ele é obrigado a aceitar a string se existir alguma escolha de caminho que leva à aceitação.

Autômato Finito Não-Determinístico




- Que linguagem este autômato reconhece?
 - **Obs.:** Ele é obrigado a aceitar a string se existir alguma escolha de caminho que leva à aceitação.
 - vazio ou um número de 'as' que são múltiplos de 3 ou de 2.

Autômato Finito Não-Determinístico



Autômato Finito Não-Determinístico



- Que linguagem este autômato reconhece?

Autômato Finito Não-Determinístico

- Não são apropriados para transformar em programas de computador.

Autômato Finito Não-Determinístico

- Não são apropriados para transformar em programas de computador.
 - “Adivinhar” qual caminho deve ser seguido não é uma tarefa facilmente executada pelo hardware dos computadores.

Autômato Finito Não-Determinístico

- Não são apropriados para transformar em programas de computador.
 - “Adivinhar” qual caminho deve ser seguido não é uma tarefa facilmente executada pelo hardware dos computadores.
- NFAs se tornam úteis porque é fácil converter expressões regulares (ER) para NFA.

Autômato Finito Não-Determinístico

- Exemplos:



Convertendo ER's para NFA's

- De maneira geral, toda ER terá um NFA com uma cauda (aresta de entrada) e uma cabeça (estado final).

Convertendo ER's para NFA's

- De maneira geral, toda ER terá um NFA com uma cauda (aresta de entrada) e uma cabeça (estado final).



Convertendo ER's para NFA's

- Podemos definir essa conversão de maneira indutiva pois:



Convertendo ER's para NFA's

- Podemos definir essa conversão de maneira indutiva pois:
 - Uma ER é primitiva (único símbolo ou vazio) ou é uma combinação de outras ERs.

Convertendo ER's para NFA's


- Podemos definir essa conversão de maneira indutiva pois:
 - Uma ER é primitiva (único símbolo ou vazio) ou é uma combinação de outras ERs.
 - O mesmo vale para NFAs.

Convertendo ER's para NFA's



M^+ constructed as $M \cdot M^*$

$M?$ constructed as $M \mid \epsilon$




"abc" constructed as $a \cdot b \cdot c$

Exemplo

- ERs para IF, ID, NUM e ERROR

Exemplo

- ERs para IF, ID, NUM e ERROR



Algoritmo de Thompson - ER para AFN

```
1  Função converter_er_para_afn(pilha):
2      símbolo = pilha desempilhar
3      Se o símbolo for uma concatenação ('.'):
4          AFN1 = desempilhar pilha
5          AFN2 = desempilhar pilha
6          Criar um AFN com uma transição do final de AFN1 para o início de AFN2
7          O do início do AFN é o início de AFN1 e o final é o final de AFN2
8          Empilhar AFN
9      Se o símbolo for uma união ('|'):
10         AFN1 = desempilhar pilha
11         AFN2 = desempilhar pilha
12         Criar um AFN com um novo estado inicial q1 e um novo estado final q2
13         Adicionar uma transição de q1 para os estados iniciais de AFN1 e AFN2 com epsilon
14         Adicionar uma transição dos finais de AFN1 e AFN2 para q2 com epsilon
15         Empilhar AFN
16      Se o símbolo for um fechamento de Kleene ('*'):
17         AFN1 = desempilhar pilha
18         Criar AFN com um novo estado inicial q1 e um novo estado final q2
19         Adicionar uma transição de q1 para q2 com epsilon
20         Adicionar uma transição de q1 para o início do AFN1 com epsilon
21         Adicionar uma transição do final de AFN1 para q2 com epsilon
22         Adicionar uma transição de q2 para o início do AFN1 com epsilon
23         Empilhar AFN
24      Retornar o AFN gerado e a pilha
```

Algoritmo de Thompson - ER para AFN

```
1  Função preparar_lista(expressao_regular):
2      lista_ER = []
3      Para cada símbolo na expressao_regular:
4          Se o símbolo for um operando (caractere alfabético ou epsilon):
5              Criar um AFN com um estado inicial q1 e um estado final q2
6              Adicionar uma transição do estado q1 para o estado q2, com o símbolo lido ou epsilon
7              Adicionar AFN na lista_ER
8          Se não:
9              Adicionar símbolo na lista_ER
10     Retornar lista_ER
11
12
13  Função converter_ER_to_AFN (expressao_regular):
14     pilha = []
15     AFN = []
16     lista_ER = preparar_lista (expressao_regular)
17     Para cada símbolo na lista_ER:
18         Se símbolo não for ')':
19             Empilhar símbolo
20         Se símbolo for ')':
21             AFN, pilha = Executar converter_er_para_afn(pilha) até o primeiro '('
22     Retornar AFN gerado
```

Algoritmo de Thompson - ER para AFN

- O algoritmo de Thompson exige que as expressões regulares estejam bem formuladas, com o uso de parênteses corretos.
- Ex. $(a|b|c)$ deve ser escrito como $((a|b)|c)$.
- Bem como $(a|b)^*$ deve ser escrito como $((a|b)^*)$.

NFA vs. DFA

- DFAs são facilmente simuláveis por programas de computador.


NFA vs. DFA

- DFAs são facilmente simuláveis por programas de computador.
- NFAs são mais complexos, pois o programa teria que “adivinhar” o melhor caminho em alguns momentos.


NFA vs. DFA

- DFAs são facilmente simuláveis por programas de computador.
- NFAs são mais complexos, pois o programa teria que “adivinhar” o melhor caminho em alguns momentos.
- Outra alternativa seria tentar todas as possibilidades.

Simulando NFA para "in"




Simulando NFA para “in”




- Início (1) $\implies$ NFA pode estar em 1,4,9,14.

Simulando NFA para “in”



- Início (1) $\Rightarrow$ NFA pode estar em 1,4,9,14.
- Consome $i \Rightarrow$ NFA pode estar em 2,5,6,8,15.

Simulando NFA para “in”



- Início (1) $\Rightarrow$ NFA pode estar em 1,4,9,14.
- Consome $i \Rightarrow$ NFA pode estar em 2,5,6,8,15.
- Consome $n \Rightarrow$ NFA pode estar em 6,7,8.

ε -Closure

- $\text{Edge}(s, c)$: todos os estados alcançáveis a partir de s , consumindo c .

ε -Closure

- $\text{Edge}(s, c)$: todos os estados alcançáveis a partir de s , consumindo c .
- $\text{Closure}(S)$: todos os estados alcançáveis a partir do conjunto S , sem consumir caractere de entrada.

ε -Closure

- $\text{Edge}(s, c)$: todos os estados alcançáveis a partir de s , consumindo c .
- $\text{Closure}(S)$: todos os estados alcançáveis a partir do conjunto S , sem consumir caractere de entrada.
- $\text{Closure}(S)$ é o menor conjunto T , tal que :

ε -Closure

- $\text{Edge}(s, c)$: todos os estados alcançáveis a partir de s , consumindo c .
- $\text{Closure}(S)$: todos os estados alcançáveis a partir do conjunto S , sem consumir caractere de entrada.
- $\text{Closure}(S)$ é o menor conjunto T , tal que :

$$T = S \cup \left(\bigcup_{S \in T} \text{edge}(s, \varepsilon) \right) \quad (1)$$

Algoritmo

Computado por iteração:

$T \leftarrow S$

repita $T' \leftarrow T$

$T = T' \cup (\bigcup_{S \in T'} \mathbf{edge}(s, \varepsilon))$

até $T = T'$

Algoritmo

Da maneira que fizemos a simulação, vamos definir:

Algoritmo

Da maneira que fizemos a simulação, vamos definir:

$$\mathbf{DFAedge}(d, c) = \mathbf{closure}(\bigcup_{s \in d} \mathbf{edge}(s, c))$$

Algoritmo

Da maneira que fizemos a simulação, vamos definir:

$$\mathbf{DFAedge}(d, c) = \mathbf{closure}(\bigcup_{s \in d} \mathbf{edge}(s, c))$$

como o conjunto de estados do NFA que podemos atingir a partir do conjunto d , consumindo c .

Algoritmo

Da maneira que fizemos a simulação, vamos definir:

$$\mathbf{DFAedge}(d, c) = \mathbf{closure}(\bigcup_{s \in d} \mathbf{edge}(s, c))$$

como o conjunto de estados do NFA que podemos atingir a partir do conjunto d , consumindo c .

Estado inicial s_1 e string $c_1, \dots, c_k$.

Algoritmo

Da maneira que fizemos a simulação, vamos definir:

$$\mathbf{DFAedge}(d, c) = \mathbf{closure}(\bigcup_{s \in d} \mathbf{edge}(s, c))$$

como o conjunto de estados do NFA que podemos atingir a partir do conjunto d , consumindo c .

Estado inicial s_1 e string $c_1, \dots, c_k$.

```
 $d \leftarrow \mathbf{closure}(\{s_1\})$   
para  $i \leftarrow 1$  até  $k$   
     $d \leftarrow \mathbf{DFAedge}(d, c_i)$ 
```

Convertendo NFA em DFA

- Manipular esses conjuntos de estados é muito caro durante a simulação.

Convertendo NFA em DFA

- Manipular esses conjuntos de estados é muito caro durante a simulação.
- Solução:

Convertendo NFA em DFA

- Manipular esses conjuntos de estados é muito caro durante a simulação.
- Solução:
 - Calcular todos eles antecipadamente.

Convertendo NFA em DFA

- Manipular esses conjuntos de estados é muito caro durante a simulação.
- Solução:
 - Calcular todos eles antecipadamente.
- Isso converte um NFA em um DFA!!!

Convertendo NFA em DFA

- Manipular esses conjuntos de estados é muito caro durante a simulação.
- Solução:
 - Calcular todos eles antecipadamente.
- Isso converte um NFA em um DFA!!!
 - Cada conjunto de estados no NFA se torna um estado no DFA.

Algoritmo

```
states[0]  $\leftarrow$  {};    states[1]  $\leftarrow$  closure( $\{s_1\}$ )  
 $p \leftarrow 1$ ;     $j \leftarrow 0$   
while  $j \leq p$   
    foreach  $c \in \Sigma$   
         $e \leftarrow$  DFAedge(states[ $j$ ],  $c$ )  
        if  $e = \text{states}[i]$  for some  $i \leq p$   
            then trans[ $j$ ,  $c$ ]  $\leftarrow i$   
        else  $p \leftarrow p + 1$   
            states[ $p$ ]  $\leftarrow e$   
            trans[ $j$ ,  $c$ ]  $\leftarrow p$   
 $j \leftarrow j + 1$ 
```

Convertendo NFA em DFA

- O estado d é final se qualquer um dos estados de `states[d]` for final.

Convertendo NFA em DFA

- O estado d é final se qualquer um dos estados de `states[d]` for final.
- Pode haver vários estados finais em `states[d]`.

Convertendo NFA em DFA

- O estado d é final se qualquer um dos estados de `states[d]` for final.
- Pode haver vários estados finais em `states[d]`.
 - d será anotado com o token que ocorrer primeiro na especificação léxica (ERs) $\implies$ Regra de prioridade


Convertendo NFA em DFA

- O estado d é final se qualquer um dos estados de `states[d]` for final.
- Pode haver vários estados finais em `states[d]`.
 - d será anotado com o token que ocorrer primeiro na especificação léxica (ERs) $\implies$ Regra de prioridade
- Ao final

Convertendo NFA em DFA

- O estado d é final se qualquer um dos estados de `states[d]` for final.
- Pode haver vários estados finais em `states[d]`.
 - d será anotado com o token que ocorrer primeiro na especificação léxica (ERs) $\implies$ Regra de prioridade
- Ao final
 - Descartar `states[]` e usar `trans[]` para análise léxica.

Convertendo NFA em DFA



Convertendo NFA em DFA

- Esse é o menor autômato possível para essa linguagem?

Convertendo NFA em DFA

- Esse é o menor autômato possível para essa linguagem?
 - Não!

Convertendo NFA em DFA


- Esse é o menor autômato possível para essa linguagem?
 - Não!
 - Existem estados que são equivalentes!

Convertendo NFA em DFA

- Esse é o menor autômato possível para essa linguagem?
 - Não!
 - Existem estados que são equivalentes!
- s_1 e s_2 são equivalentes quando o autômato aceita σ começando em s_1 se e somente se ele também aceita σ começando em s_2 .

Convertendo NFA em DFA

Quais estados são equivalentes no autômato?



Convertendo NFA em DFA

- Como encontrar estados equivalentes?

Convertendo NFA em DFA

- Como encontrar estados equivalentes?
 - $\text{trans}[s_1, c] = \text{trans}[s_2, c]$ para para todo c .

Convertendo NFA em DFA

- Como encontrar estados equivalentes?
 - $\text{trans}[s_1, c] = \text{trans}[s_2, c]$ para para todo c .
 - Não é suficiente!!!

Convertendo NFA em DFA

- Como encontrar estados equivalentes?
 - $\text{trans}[s_1, c] = \text{trans}[s_2, c]$ para para todo c .
 - Não é suficiente!!!
- s_1 e s_2 são equivalentes quando o autômato aceita σ começando em s_1 se e somente se ele também aceita σ começando em s_2 .

Análise Léxica



Universidade Federal do Ceará - Campus de Quixadá

Lucas Ismaily
ismailybf@ufc.br

Semestre 2025.1

Compiladores

Baseado nos slides do Prof. Sandro Rigo (IC-Unicamp)